
## Школа глубокого обучения ФПМИ МФТИ

## Домашнее задание. Полносвязные и свёрточные нейронные сети

В этом занятии вам предстоит потренироваться построению нейронных сетей с помощью библиотеки Pytorch. Делать мы это будем на нескольких датасетах.

```
import numpy as np

import seaborn as sns
from matplotlib import pyplot as plt

from sklearn.datasets import make_moons
from sklearn.model_selection import train_test_split

import torch
from torch import nn
from torch.nn import functional as F

from torch.utils.data import TensorDataset, DataLoader

sns.set(style="darkgrid", font_scale=1.4)
```

# Часть 1. Датасет moons

Давайте сгенерируем датасет и посмотрим на него!

```
X, y = make_moons(n_samples=10000, random_state=42, noise=0.1)
```

```
plt.figure(figsize=(16, 10))
plt.title("Dataset")
plt.scatter(X[:, 0], X[:, 1], c=y, cmap="viridis")
plt.show()
```

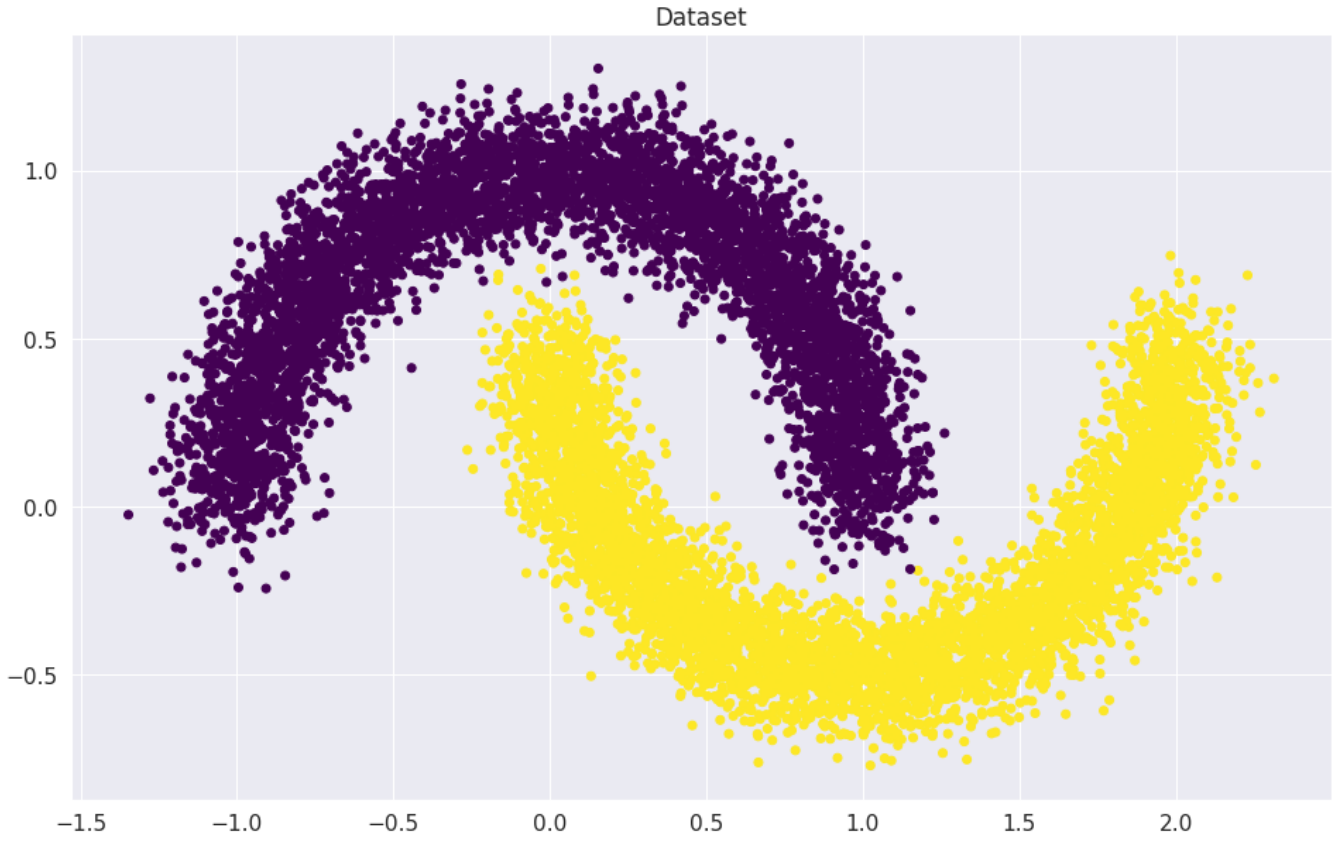


Сделаем train/test split

```
X_train, X_val, y_train, y_val = train_test_split(X, y, random_state=42)
```

## Загрузка данных

В PyTorch загрузка данных как правило происходит налету (иногда датасеты не помещаются в оперативную память). Для этого используются две сущности `Dataset` и `DataLoader`.

1. `Dataset` загружает каждый объект по отдельности.
2. `DataLoader` группирует объекты из `Dataset` в батчи.

Так как наш датасет достаточно маленький мы будем использовать `TensorDataset`. Все, что нам нужно, это перевести из массива numpy в тензор с типом `torch.float32`.

### Задание. Создайте тензоры с обучающими и тестовыми данными

```
X_train_t =  torch.from_numpy(X_train)
y_train_t =  torch.from_numpy(y_train)
X_val_t = torch.from_numpy(X_val)
y_val_t =  torch.from_numpy(y_val)
```

Создаем `Dataset` и `DataLoader`.

```
train_dataset = TensorDataset(X_train_t, y_train_t)
val_dataset = TensorDataset(X_val_t, y_val_t)
train_dataloader = DataLoader(train_dataset, batch_size=128)
val_dataloader = DataLoader(val_dataset, batch_size=128)
```

## Logistic regression is my profession

**Напоминание** Давайте вспоним, что происходит в логистической регрессии. На входе у нас есть матрица объект-признак X и столбец-вектор $y$ – метки из $\{0, 1\}$ для каждого объекта. Мы хотим найти такую матрицу весов $W$ и смещение $b$ (bias), что наша модель $XW + b$ будет каким-то образом предсказывать класс объекта. Как видно на выходе наша модель может выдавать число в интервале от $(-\infty; \infty)$. Этот выход как правило называют "логитами" (logits). Нам необходимо перевести его на интервал от $[0; 1]$ для того, чтобы он выдавал нам вероятность принадлежности объекта к кассу один, также лучше, чтобы эта функция была монотонной, быстро считалась, имела производную и на $-\infty$ имела значение $0$, а на $+\infty$ имела значение $1$. Такой класс функций называется сигмоидыю. Чаще всего в качестве сигмоида берут

$$\sigma(x) = \frac{1}{1 + e^{-x}}.$$

## Задание. Реализация логистической регрессии

Вам необходимо написать модуль на PyTorch реализующий $logits = XW + b$, где $W$ и $b$ – параметры (`nn.Parameter`) модели. Иначе говоря, здесь мы реализуем своими руками модуль `nn.Linear` (в этом пункте его использование запрещено). Инициализируйте веса нормальным распределением (`torch.randn`).

```
class LinearRegression(nn.Module):
    def __init__(self, in_features: int, out_features: int, bias: bool = True):
        super().__init__()
        self.weights = nn.Parameter(torch.randn(out_features, in_features))
        self.bias = bias

        if bias:
            self.bias_term = nn.Parameter(torch.randn(out_features)) # YOUR CODE GOES

    def forward(self, x):
        x = x.float()
        x =  x @ self.weights.t() # YOUR CODE GOES HERE
        if self.bias:
            x +=  self.bias # YOUR CODE GOES HERE
        return x


linear_regression = LinearRegression(2, 1)
loss_function = nn.BCEWithLogitsLoss()
optimizer = torch.optim.SGD(linear_regression.parameters(), lr=0.05)
```

**Вопрос 1.** Сколько обучаемых параметров у получившейся модели?

```
#YOUR CODE
list(linear_regression.parameters())
```

```
[Parameter containing:
 tensor([[1.9231, 0.4670]], requires_grad=True), Parameter containing:
 tensor([0.9049], requires_grad=True)]
```

**Ответ**: 3

## Train loop

Вот псевдокод, который поможет вам разобраться в том, что происходит во время обучения

```
for epoch in range(max_epochs):  # <---------- итерируемся по датасету несколько раз
    for x_batch, y_batch in dataset:  # <------ итерируемся по датасету. Так как мы использу
        optimizer.zero_grad()  # <------------ обуляем градиенты модели
        outp = model(x_batch)  # <------------ получаем "логиты" из модели
        loss = loss_func(outp, y_batch)  # <--- считаем "лосс" для логистической регрессии
        loss.backward()  # <------------------ считаем градиенты
        optimizer.step()  # <----------------- делаем шаг градиентного спуска
        if convergence:  # <------------------ в случае сходимости выходим из цикла
            break
```

В коде ниже добавлено логирование `accuracy` и `loss`.

## Задание. Реализация цикла обучения

```
tol = 1e-3
losses = []
max_epochs = 100
prev_weights = torch.zeros_like(linear_regression.weights)
stop_it = False
for epoch in range(max_epochs):
    for it, (X_batch, y_batch) in enumerate(train_dataloader):
        optimizer.zero_grad()
        outp =  linear_regression.forward(X_batch.float()).squeeze() # YOUR CODE. Use
        loss =  loss_function(outp, y_batch.float()) # YOUR CODE. Compute loss
        #print(outp.shape)
        #print(y_batch.shape)
        loss.backward()
        losses.append(loss.detach().flatten()[0])
        optimizer.step()
        probabilities =  torch.sigmoid(outp) # YOUR CODE. Compute probabilities
        preds = (probabilities > 0.5).type(torch.long)
        batch_acc = (preds.flatten() == y_batch).type(torch.float32).sum() / y_batch.

        if it % 500000 == 0:
            print(f"Iteration: {it + epoch*len(train_dataset)}\nBatch accuracy: {batc
        current_weights = linear_regression.weights.detach().clone()
        if (prev_weights - current_weights).abs().max() < tol:
            print(f"\nIteration: {it + epoch*len(train_dataset)}.Convergence. Stoppin
            stop_it = True
            break
        prev_weights = current_weights
    if stop_it:
        break

    Iteration: 0
    Batch accuracy: 0.6171875
```

```
Iteration: 7500
Batch accuracy: 0.640625
Iteration: 15000
Batch accuracy: 0.6953125
Iteration: 22500
Batch accuracy: 0.765625
Iteration: 30000
Batch accuracy: 0.796875
Iteration: 37500
Batch accuracy: 0.8125
Iteration: 45000
Batch accuracy: 0.84375
Iteration: 52500
Batch accuracy: 0.84375
Iteration: 60000
Batch accuracy: 0.859375
Iteration: 67500
Batch accuracy: 0.8515625
Iteration: 75000
Batch accuracy: 0.8515625
Iteration: 82500
Batch accuracy: 0.8671875
Iteration: 90000
Batch accuracy: 0.8671875
Iteration: 97500
Batch accuracy: 0.8671875
Iteration: 105000
Batch accuracy: 0.8671875
Iteration: 112500
Batch accuracy: 0.8671875

Iteration: 112547.Convergence. Stopping iterations.
```

**Вопрос 2.**

Сколько итераций потребовалось, чтобы алгоритм сошелся?

**Ответ:** 112547

## Визуализируем результаты

```
plt.figure(figsize=(12, 8))
plt.plot(range(len(losses)), losses)
plt.xlabel("Iteration")
plt.ylabel("Loss")
plt.show()
```

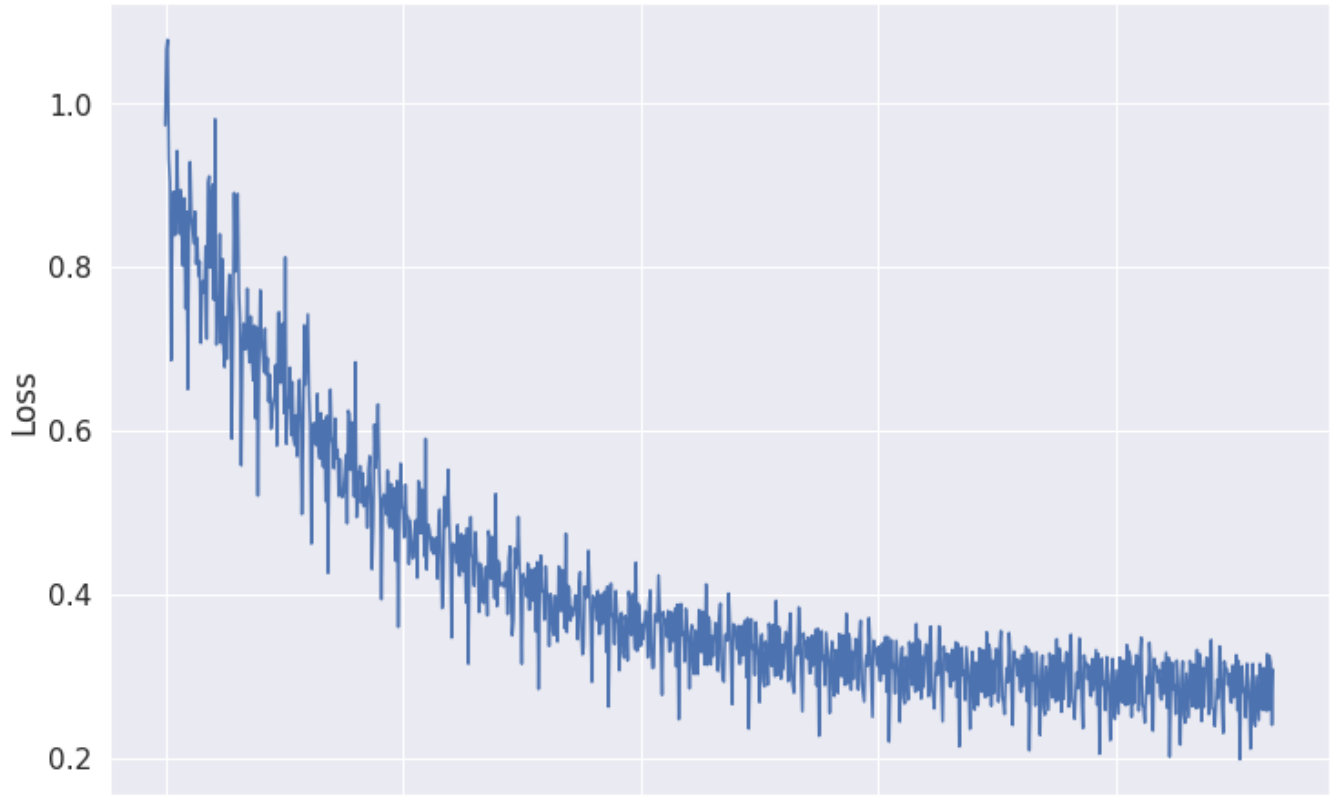


```
import numpy as np

sns.set(style="white")

xx, yy = np.mgrid[-1.5:2.5:.01, -1.:1.5:.01]
grid = np.c_[xx.ravel(), yy.ravel()]
batch = torch.from_numpy(grid).type(torch.float32)
with torch.no_grad():
    probs = torch.sigmoid(linear_regression(batch).reshape(xx.shape))
    probs = probs.numpy().reshape(xx.shape)

f, ax = plt.subplots(figsize=(16, 10))
ax.set_title("Decision boundary", fontsize=14)
contour = ax.contourf(xx, yy, probs, 25, cmap="RdBu",
                      vmin=0, vmax=1)
ax_c = f.colorbar(contour)
ax_c.set_label("$P(y = 1)$")
ax_c.set_ticks([0, .25, .5, .75, 1])

ax.scatter(X[100:,0], X[100:, 1], c=y[100:], s=50,
           cmap="RdBu", vmin=-.2, vmax=1.2,
           edgecolor="white", linewidth=1)

ax.set(xlabel="$X_1$", ylabel="$X_2$")
plt.show()
```

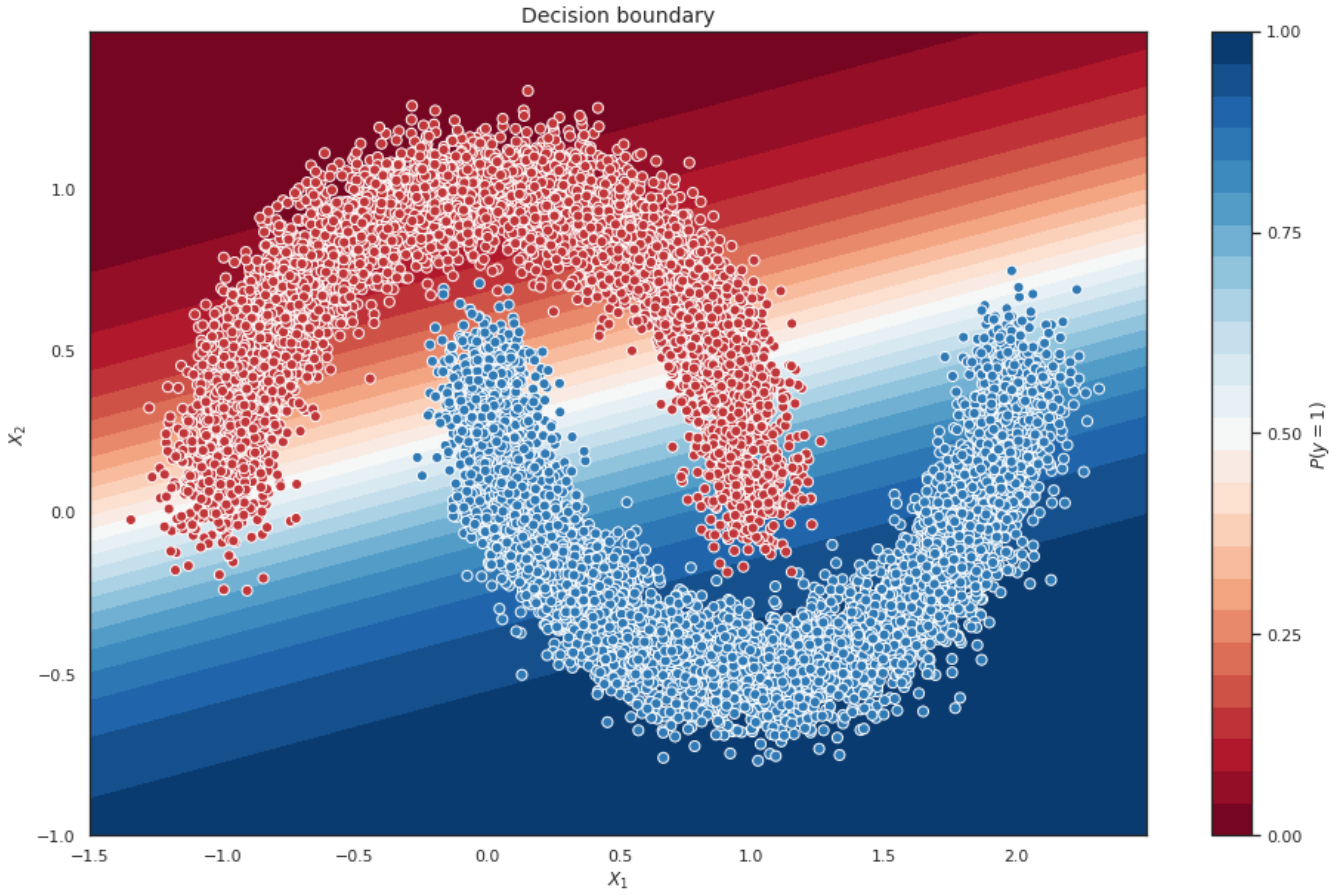


## Задание. Реализуйте predict и посчитайте accuracy на test.

```
@torch.no_grad()
def predict(dataloader, model):
    model.eval()
    predictions = np.array([])
    for x_batch, _ in dataloader:
        #<YOUR CODE>
        outp = model(x_batch)
        probabilities =  torch.sigmoid(outp)
        preds = (probabilities > 0.5).type(torch.float) #YOUR CODE. Compute predictio
        predictions = np.hstack((predictions, preds.numpy().flatten()))
    return predictions.flatten()


from sklearn.metrics import accuracy_score

# YOUR CODE. Compute total accuracy
accuracy_score(y_val_t, predict(val_dataloader, linear_regression))
```

```
0.886
```

**Вопрос 3**

Какое `accuracy` получается после обучения?

**Ответ:** 0.886

# Часть 2. Датасет MNIST

Датасет MNIST содержит рукописные цифры. Загрузим датасет и создадим DataLoader-ы. Пример можно найти в семинаре по полносвязным нейронным сетям.

```
import os
from torchvision.datasets import MNIST
import torchvision.transforms as tfs

data_tfs = tfs.Compose([
    tfs.ToTensor(),
    tfs.Normalize((0.5), (0.5))
])

# install for train and test
root = './'
train_dataset = MNIST(root, train=True,  transform=data_tfs, download=True)
val_dataset  = MNIST(root, train=False, transform=data_tfs, download=True)

train_dataloader =  DataLoader(train_dataset, batch_size=4, shuffle=True, num_workers
valid_dataloader =  DataLoader(val_dataset, batch_size=128, shuffle=False, num_worker
```

# Часть 2.1. Полносвязные нейронные сети

Сначала решим MNIST с помощью полносвязной нейронной сети.

```
class Identical(nn.Module):
    def forward(self, x):
        return x
```

## Задание. Простая полносвязная нейронная сеть

Создайте полносвязную нейронную сеть с помощью класса Sequential. Сеть состоит из:

- Уплощения матрицы в вектор (nn.Flatten);

- Двух скрытых слоёв из 128 нейронов с активацией nn.ELU;
- Выходного слоя с 10 нейронами.

Задайте лосс для обучения (кросс-энтропия).

```
activation = nn.ELU

#features = 784
#classes = 10

model = nn.Sequential(
    nn.Flatten(),
    #YOUR CODE. Add layers to your sequential class
    nn.Linear(784, 128),
    activation(),
    nn.Linear(128, 10)
)


criterion = nn.CrossEntropyLoss() #YOUR CODE. Select loss function
optimizer = torch.optim.Adam(model.parameters())

loaders = {"train": train_dataloader, "valid": valid_dataloader}


device = "cuda" if torch.cuda.is_available() else "cpu"
```

## Train loop (seriously)

Давайте разберемся с кодом ниже, который подойдет для 90% задач в будущем.

```
 for epoch in range(max_epochs):  # <--------------- итерируемся по датасету несколько раз
     for k, dataloader in loaders.items():  # <----- несколько dataloader для train / valid /
         for x_batch, y_batch in dataloader:  # <--- итерируемся по датасету. Так как мы испо
             if k == "train":
                 model.train()  # <----------------- переводим модель в режим train
                 optimizer.zero_grad()  # <--------- обнуляем градиенты модели
                 outp = model(x_batch)
                 loss = criterion(outp, y_batch) # <-считаем "лосс" для логистической регресс
                 loss.backward()  # <--------------- считаем градиенты
                 optimizer.step()  # <-------------- делаем шаг градиентного спуска
             else:  # <---------------------------- test/eval
                 model.eval()  # <----------------- переводим модель в режим eval
                 with torch.no_grad():  # <--------- НЕ считаем градиенты
                     outp = model(x_batch)  # <------------- получаем "логиты" из модели
             count_metrics(outp, y_batch)  # <-------------- считаем метрики
```

## Задание. Дополните цикл обучения.

```
max_epochs = 10
accuracy = {"train": [], "valid": []}
for epoch in range(max_epochs):
    epoch_correct = 0
    epoch_all = 0
    for k, dataloader in loaders.items():
        for x_batch, y_batch in dataloader:
            if k == "train":
                 # YOUR CODE GOES HERE
                 model.train()
                 optimizer.zero_grad()
                 outp = model.forward(x_batch)
            else:
                 # YOUR CODE GOES HERE
                 model.eval()
                 with torch.no_grad():
                   outp = model(x_batch)
            preds = outp.argmax(-1)
            correct =  (preds==y_batch).sum() # YOUR CODE GOES HERE
            all =  outp.shape[0] # YOUR CODE GOES HERE
            epoch_correct += correct.item()
            epoch_all += all
            if k == "train":
                loss = criterion(outp, y_batch)
                loss.backward() # YOUR CODE GOES HERE
                optimizer.step() # YOUR CODE GOES HERE
        if k == "train":
            print(f"Epoch: {epoch+1}")
        print(f"Loader: {k}. Accuracy: {epoch_correct/epoch_all}")
        accuracy[k].append(epoch_correct/epoch_all)
```

```
Epoch: 1
Loader: train. Accuracy: 0.90965
Loader: valid. Accuracy: 0.9147571428571428
Epoch: 2
Loader: train. Accuracy: 0.9480666666666666
Loader: valid. Accuracy: 0.9479142857142857
Epoch: 3
Loader: train. Accuracy: 0.9579166666666666
Loader: valid. Accuracy: 0.9569142857142857
Epoch: 4
Loader: train. Accuracy: 0.9620166666666666
Loader: valid. Accuracy: 0.9611571428571428
Epoch: 5
Loader: train. Accuracy: 0.9664
Loader: valid. Accuracy: 0.9665714285714285
Epoch: 6
```

```
Loader: train. Accuracy: 0.9686
Loader: valid. Accuracy: 0.9668285714285715
Epoch: 7
Loader: train. Accuracy: 0.9693
Loader: valid. Accuracy: 0.9687
Epoch: 8
Loader: train. Accuracy: 0.9719833333333333
Loader: valid. Accuracy: 0.9711
Epoch: 9
Loader: train. Accuracy: 0.9729166666666667
Loader: valid. Accuracy: 0.9722428571428572
Epoch: 10
Loader: train. Accuracy: 0.9750166666666666
Loader: valid. Accuracy: 0.9740714285714286
```

## Задание. Протестируйте разные функции активации.

Попробуйте разные функции активации. Для каждой функции активации посчитайте массив validation accuracy. Лучше реализовать это в виде функции, берущей на вход активацию и получающей массив из accuracies.

```
elu_accuracy = accuracy["valid"]
```

```
# YOUR CODE. Do the same thing with other activations (it's better to wrap into a fun

def test_activation_function(activation):
    #YOUR CODE
    model = nn.Sequential(
      nn.Flatten(),
      #YOUR CODE. Add layers to your sequential class
      nn.Linear(784, 128),
      activation(),
      nn.Linear(128, 10)
    )
    criterion = nn.CrossEntropyLoss() #YOUR CODE. Select loss function
    optimizer = torch.optim.Adam(model.parameters())

    loaders = {"train": train_dataloader, "valid": valid_dataloader}

    max_epochs = 10
    accuracy = {"train": [], "valid": []}
    for epoch in range(max_epochs):
      epoch_correct = 0
      epoch_all = 0
      for k, dataloader in loaders.items():
        for x_batch, y_batch in dataloader:
            if k == "train":
                 # YOUR CODE GOES HERE
                 model.train()
```

```
                optimizer.zero_grad()
                outp = model.forward(x_batch)
            else:
                # YOUR CODE GOES HERE
                model.eval()
                with torch.no_grad():
                  outp = model(x_batch)
            preds = outp.argmax(-1)
            correct =  (preds==y_batch).sum() # YOUR CODE GOES HERE
            all =  outp.shape[0] # YOUR CODE GOES HERE
            epoch_correct += correct.item()
            epoch_all += all
            if k == "train":
                loss = criterion(outp, y_batch)
                loss.backward() # YOUR CODE GOES HERE
                optimizer.step() # YOUR CODE GOES HERE
        if k == "train":
            print(f"Epoch: {epoch+1}")
        print(f"Loader: {k}. Accuracy: {epoch_correct/epoch_all}")
        accuracy[k].append(epoch_correct/epoch_all)
        return accuracy["valid"]



plain_accuracy = test_activation_function(Identical)
relu_accuracy = test_activation_function(nn.ReLU)
leaky_relu_accuracy = test_activation_function(nn.LeakyReLU) #YOUR CODE
```

```
Epoch: 1
Loader: train. Accuracy: 0.8586833333333334
Loader: valid. Accuracy: 0.8593
Epoch: 2
Loader: train. Accuracy: 0.8824
Loader: valid. Accuracy: 0.8846142857142857
Epoch: 3
Loader: train. Accuracy: 0.8901666666666667
Loader: valid. Accuracy: 0.8914
Epoch: 4
Loader: train. Accuracy: 0.8939833333333334
Loader: valid. Accuracy: 0.8938571428571429
Epoch: 5
Loader: train. Accuracy: 0.8968
Loader: valid. Accuracy: 0.8991285714285714
Epoch: 6
Loader: train. Accuracy: 0.8983333333333333
Loader: valid. Accuracy: 0.8994428571428571
Epoch: 7
Loader: train. Accuracy: 0.8982666666666667
Loader: valid. Accuracy: 0.8929142857142857
Epoch: 8
Loader: train. Accuracy: 0.8998666666666667
Loader: valid. Accuracy: 0.9015428571428571
Epoch: 9
Loader: train. Accuracy: 0.90125
```

```
Loader: valid. Accuracy: 0.9019285714285714
Epoch: 10
Loader: train. Accuracy: 0.9029333333333334
Loader: valid. Accuracy: 0.9034714285714286
Epoch: 1
Loader: train. Accuracy: 0.9027666666666667
Loader: valid. Accuracy: 0.9083428571428571
Epoch: 2
Loader: train. Accuracy: 0.942
Loader: valid. Accuracy: 0.9412142857142857
Epoch: 3
Loader: train. Accuracy: 0.9509166666666666
Loader: valid. Accuracy: 0.9515571428571429
Epoch: 4
Loader: train. Accuracy: 0.9570666666666666
Loader: valid. Accuracy: 0.9572714285714286
Epoch: 5
Loader: train. Accuracy: 0.9607666666666667
Loader: valid. Accuracy: 0.9609714285714286
Epoch: 6
Loader: train. Accuracy: 0.9626666666666667
Loader: valid. Accuracy: 0.9593857142857143
Epoch: 7
Loader: train. Accuracy: 0.9638333333333333
Loader: valid. Accuracy: 0.9636
Epoch: 8
Loader: train. Accuracy: 0.9656
Loader: valid. Accuracy: 0.9638142857142857
Epoch: 9
Loader: train. Accuracy: 0.9676833333333333
Loader: valid. Accuracy: 0.9668142857142857
Epoch: 10
Loader: train. Accuracy: 0.9683333333333334
```

## Accuracy

Построим график accuracy/epoch для каждой функции активации.

```
sns.set(style="darkgrid", font_scale=1.4)

plt.figure(figsize=(16, 10))
plt.title("Valid accuracy")
plt.plot(range(max_epochs), plain_accuracy, label="No activation", linewidth=2)
plt.plot(range(max_epochs), relu_accuracy, label="ReLU activation", linewidth=2)
plt.plot(range(max_epochs), leaky_relu_accuracy, label="LeakyReLU activation", linewi
plt.plot(range(max_epochs), elu_accuracy, label="ELU activation", linewidth=2)
plt.legend()
plt.xlabel("Epoch")
plt.show()


plt.figure(figsize=(16, 10))
plt.title("Valid accuracy")
plt.plot(range(max_epochs), relu_accuracy, label="ReLU activation", linewidth=2)
```

```
plt.plot(range(max_epochs), leaky_relu_accuracy, label="LeakyReLU activation", linewi
plt.plot(range(max_epochs), elu_accuracy, label="ELU activation", linewidth=2)
plt.legend()
plt.xlabel("Epoch")
plt.show()
```

**Вопрос 4** Какая из активаций показала наивысший `accuracy` к концу обучения?

**Ответ:** leaky_relu_accuracy показала наивысший результат = 0.97

# Часть 2.2 Сверточные нейронные сети

## Ядра

Сначала немного поработам с самим понятием ядра свёртки.

```
!wget https://img.the-village.kz/the-village.com.kz/post-cover/5x5-I6oiwjmq79dMCZMEbA
```

```
--2021-11-15 19:18:31--  https://img.the-village.kz/the-village.com.kz/post-cove
Resolving img.the-village.kz (img.the-village.kz)... 144.76.208.75
Connecting to img.the-village.kz (img.the-village.kz)|144.76.208.75|:443... conn
HTTP request sent, awaiting response... 301 Moved Permanently
Location: https://img.the-village-kz.com/the-village.com.kz/post-cover/5x5-I6oiw
--2021-11-15 19:18:32--  https://img.the-village-kz.com/the-village.com.kz/post-
Resolving img.the-village-kz.com (img.the-village-kz.com)... 144.76.208.75
Connecting to img.the-village-kz.com (img.the-village-kz.com)|144.76.208.75|:443
HTTP request sent, awaiting response... 200 OK
Length: 49337 (48K) [image/jpeg]
Saving to: ‘sample_photo.jpg’

sample_photo.jpg    100%[===================>]  48.18K   162KB/s    in 0.3s

2021-11-15 19:18:33 (162 KB/s) - ‘sample_photo.jpg’ saved [49337/49337]
```

```
import cv2
sns.set(style="white")
img = cv2.imread("sample_photo.jpg")
RGB_img = cv2.cvtColor(img, cv2.COLOR_BGR2RGB)
plt.figure(figsize=(12, 8))
plt.imshow(RGB_img)
plt.show()
```


Попробуйте посмотреть как различные свертки влияют на фото. Например, попробуйте А)

```
[0, 0, 0],
[0, 1, 0],
[0, 0, 0]
```

Б)

```
[0, 1, 0],
[0, -2, 0],
[0, 1, 0]
```

В)

```
[0, 0, 0],
[1, -2, 1],
[0, 0, 0]
```

Г)

```
[0, 1, 0],
[1, -4, 1],
[0, 1, 0]
```

Д)

```
 [0, -1, 0],
 [-1, 5, -1],
 [0, -1, 0]
```

Е)

```
 [0.0625, 0.125, 0.0625],
 [0.125, 0.25, 0.125],
 [0.0625, 0.125, 0.0625]
```

Не стесняйтесь пробовать свои варианты!

```
img_t = torch.from_numpy(RGB_img).type(torch.float32).unsqueeze(0)
kernel = torch.tensor([
    [0, 1, 0],
    [0, -2, 0],
    [0, 1, 0]
]).reshape(1, 1, 3, 3).type(torch.float32)

kernel = kernel.repeat(3, 3, 1, 1)
img_t = img_t.permute(0, 3, 1, 2)  # [BS, H, W, C] -> [BS, C, H, W]
img_t = nn.ReflectionPad2d(1)(img_t)  # Pad Image for same output size

result = F.conv2d(img_t, kernel)[0]  #


plt.figure(figsize=(12, 8))
result_np = result.permute(1, 2, 0).numpy() / 256 / 3

plt.imshow(result_np)
plt.show()
```

```
Clipping input data to the valid range for imshow with RGB data ([0..1] for floa
```


**Вопрос 5.** Как можно описать действия ядер, приведенных выше? Сопоставьте для каждой буквы число.

1) Размытие

2) Увеличение резкости

3) Тождественное преобразование

4) Выделение вертикальных границ

5) Выделение горизонтальных границ

6) Выделение границ

**Ответ:** А - 3, Б - 5, В - 4, Г - 6, Д - 2, Е - 1

## Задание. Реализуйте LeNet

Если мы сделаем параметры сверток обучаемыми, то можем добиться хороших результатов для задач компьютерного зрения. Реализуйте архитектуру LeNet, предложенную еще в 1998 году! На этот раз используйте модульную структуру (без помощи класса Sequential).

Наша нейронная сеть будет состоять из

- Свёртки 3x3 (1 карта на входе, 6 на выходе) с активацией ReLU;
- MaxPooling-а 2x2;
- Свёртки 3x3 (6 карт на входе, 16 на выходе) с активацией ReLU;
- MaxPooling-а 2x2;
- Уплощения (nn.Flatten);
- Полносвязного слоя со 120 нейронами и активацией ReLU;
- Полносвязного слоя с 84 нейронами и активацией ReLU;
- Выходного слоя из 10 нейронов.

```
class LeNet(nn.Module):
    def __init__(self):
        super(LeNet, self).__init__()
        # 1 input image channel, 6 output channels, 3x3 square conv kernel
        self.conv1 = nn.Conv2d(1, 6, 3)
        self.pool1 = nn.MaxPool2d(2) #YOUR CODE
        self.conv2 = nn.Conv2d(6, 16, 3)#YOUR CODE
        self.pool2 = nn.MaxPool2d(2) #YOUR CODE
        self.fc1 = nn.Linear(16 * 5 * 5, 120) #YOUR CODE
        self.fc2 = nn.Linear(120, 84) #YOUR CODE
        self.fc3 = nn.Linear(84, 10)#YOUR CODE

    def forward(self, x):
        x = F.max_pool2d(F.relu(self.conv1(x)), (2,2)) #YOUR CODE. Apply layers creat
        x = F.max_pool2d(F.relu(self.conv2(x)), 2)
        x = x.view(-1, int(x.nelement() / x.shape[0]))
        x = F.relu(self.fc1(x))
        x = F.relu(self.fc2(x))
        x = self.fc3(x)
        return x



model = LeNet().to(device)

criterion = nn.CrossEntropyLoss()
optimizer = torch.optim.Adam(model.parameters())

loaders = {"train": train_dataloader, "valid": valid_dataloader}
```

## Задание. Обучите CNN

Используйте код обучения, который вы написали для полносвязной нейронной сети.

```
max_epochs = 10
accuracy = {"train": [], "valid": []}
for epoch in range(max_epochs):
    epoch_correct = 0
    epoch_all = 0
    for k, dataloader in loaders.items():
        for x_batch, y_batch in dataloader:
            if k == "train":
                 # YOUR CODE GOES HERE
                 model.train()
                 optimizer.zero_grad()
                 outp = model.forward(x_batch)
            else:
                 # YOUR CODE GOES HERE
```

```
                model.eval()
                with torch.no_grad():
                  outp = model(x_batch)
            preds = outp.argmax(-1)
            correct =  (preds==y_batch).sum() # YOUR CODE GOES HERE
            all =  outp.shape[0] # YOUR CODE GOES HERE
            epoch_correct += correct.item()
            epoch_all += all
            if k == "train":
                loss = criterion(outp, y_batch)
                loss.backward() # YOUR CODE GOES HERE
                optimizer.step() # YOUR CODE GOES HERE
        if k == "train":
            print(f"Epoch: {epoch+1}")
        print(f"Loader: {k}. Accuracy: {epoch_correct/epoch_all}")
        accuracy[k].append(epoch_correct/epoch_all)
```

```
Epoch: 1
Loader: train. Accuracy: 0.9531166666666666
Loader: valid. Accuracy: 0.9562714285714286
Loader: valid. Accuracy: 0.9815571428571429
Epoch: 3
Loader: train. Accuracy: 0.9851666666666666
Loader: valid. Accuracy: 0.9851
Epoch: 4
Loader: train. Accuracy: 0.9884333333333334
Loader: valid. Accuracy: 0.9881571428571428
Epoch: 5
Loader: train. Accuracy: 0.9892666666666666
Loader: valid. Accuracy: 0.9888285714285714
Epoch: 6
Loader: train. Accuracy: 0.9900333333333333
Loader: valid. Accuracy: 0.9891714285714286
Epoch: 7
Loader: train. Accuracy: 0.9916833333333334
Loader: valid. Accuracy: 0.9910142857142857
Epoch: 8
Loader: train. Accuracy: 0.9916333333333334
Loader: valid. Accuracy: 0.9907857142857143
Epoch: 9
Loader: train. Accuracy: 0.9927
Loader: valid. Accuracy: 0.9919571428571429
Epoch: 10
Loader: train. Accuracy: 0.993
Loader: valid. Accuracy: 0.9904857142857143
```

```
lenet_accuracy = accuracy["valid"]
```

Сравним с предыдущем пунктом

```
plt.figure(figsize=(16, 10))
plt.title("Valid accuracy")
```

```
plt.plot(range(max_epochs), relu_accuracy, label="ReLU activation", linewidth=2)
plt.plot(range(max_epochs), leaky_relu_accuracy, label="LeakyReLU activation", linewi
plt.plot(range(max_epochs), elu_accuracy, label="ELU activation", linewidth=2)
plt.plot(range(max_epochs), lenet_accuracy, label="LeNet", linewidth=2)
plt.legend()
plt.xlabel("Epoch")
plt.show()
```

**Вопрос 6** Какое `accuracy` получается после обучения с точностью до двух знаков после запятой?

**Ответ:** 0.99